TC260

全国网络安全标准化技术委员会技术文件

TC260-003

生成式人工智能服务安全基本要求

Basic security requirements for generative artificial intelligence service

2024-02-29 发布

全国网络安全标准化技术委员会发布

目 次

前言 II

1 范围 1

2 规范性引用文件 1

3 术语和定义 1

4 总则 1

5 语料安全要求 2

5.1 语料来源安全要求 2

5.2 语料内容安全要求 2

5.3 语料标注安全要求 3

6 模型安全要求 3

7 安全措施要求 4

8 其他要求 5

8.1 关键词库 5

8.2 生成内容测试题库 5

8.3 拒答测试题库 6

8.4 分类模型 6

9 安全评估要求 6

9.1 评估方法 6

9.2 语料安全评估 7

9.3 生成内容安全评估 7

9.4 问题拒答评估 7

附录 A 语料及生成内容的主要安全风险 8

参考文献 10

前　言

本文件由全国网络安全标准化技术委员会（SAC/TC260）发布。

本文件起草单位：中国电子技术标准化研究院、国家计算机网络应急技术处理协调中心、北京中关村实验室、浙江大学、上海人工智能实验室、北京邮电大学、北京百度网讯科技有限公司、北京百川智能科技有限公司、复旦大学、阿里云计算有限公司、上海稀宇科技有限公司、上海商汤智能科技有限公司、科大讯飞股份有限公司、上海燧原科技有限公司、北京智谱华章科技有限公司、中国政法大学、北京深言科技有限责任公司、北京理工大学、上海交通大学、清华大学、中国科学院软件研究所、中国科学院信息工程研究所、北京航空航天大学、北京天融信网络安全技术有限公司、华为云计算技术有限公司、蚂蚁科技集团股份有限公司、贝壳找房（北京）科技有限公司、中国网络安全审查认证和市场监管大数据中心、公安部第三研究所、国家信息中心、国家计算机网络与信息安全管理中心北京分中心、广州市动悦信息技术有限公司、中国移动通信集团有限公司、杭州云麓知道科技有限公司、中国联合网络通信有限公司。

本文件主要起草人：姚相振、上官晓丽、郝春亮、张震、徐恪、任奎、杨珉、陈洋、秦湛、谭知行、张妍婷、王志波、周琳娜、杨忠良、成瑾、包沉浮、张凌寒、孙彦新、彭韬、邱锡鹏、蒋慧、何延哲、杨光、赵芸伟、洪延青、王士进、郭建领、徐浩、彭骏涛、梅敬青、霍启超、许晓耕、王姣、王凤娇、张谧、张沅、张立武、王蕊、贾开、赵静、石琳、张严、薛智慧、何永春、林冠辰、王雨晨、郑子木、张雨桐、杨雨晨、徐晖宇、王笑尘、赵睿斌、江为强、丁治国、刘楠、刘晰尧、康永萌、曹东欧、吴年京、陶冶。

生成式人工智能服务安全基本要求

1 范围

本文件规定了生成式人工智能服务在安全方面的基本要求，包括语料安全、模型安全、安全措施等，并给出了安全评估要求。

本文件适用于服务提供者开展安全评估、提高安全水平，也可为相关主管部门评判生成式人工智能服务安全水平提供参考。

2 规范性引用文件

下列文件中的内容通过文中的规范性引用而构成本文件必不可少的条款。其中，注日期的引用文件，仅该日期对应的版本适用于本文件；不注日期的引用文件，其最新版本（包括所有的修改单）适用于本文件。

GB/T 25069—2022 信息安全技术 术语

3 术语和定义

GB/T 25069—2022界定的以及下列术语和定义适用于本文件。

3.1

生成式人工智能服务 generative artificial intelligence service

利用生成式人工智能技术向中华人民共和国境内公众提供生成文本、图片、音频、视频等内容的服务。

3.2

服务提供者 service provider

以交互界面、可编程接口等形式提供生成式人工智能服务的组织或个人。

3.3

训练语料 training data

所有直接作为模型训练输入的数据，包括预训练、优化训练过程中的输入数据。

注：以下简称“语料”。

3.4

抽样合格率 sampling qualified rate

抽样中不包含本文件附录A所列出31种安全风险的样本所占的比例。

3.5

基础模型 foundation model

在大量数据上训练的，用于普适性目标、可优化适配多种下游任务的深度神经网络模型。

3.6

违法不良信息 illegal and unhealthy information

《网络信息内容生态治理规定》中指出的11类违法信息以及9类不良信息的统称。

注：本文件关注的违法不良信息主要是指包含附录A.1到A.4中29种安全风险的信息。

4 总则

本文件支撑《生成式人工智能服务管理暂行办法》，提出了服务提供者需遵循的安全基本要求。服务提供者在按照有关要求履行备案手续时，按照本文件第9章要求进行安全评估，并提交评估报告。

除本文件提出的基本要求外，服务提供者应自行按照我国法律法规以及国家标准相关要求做好网络安全、数据安全、个人信息保护等方面的其他安全工作。服务提供者应紧密注意生成式人工智能可能带来的长期风险，谨慎对待可能具备欺骗人类、自我复制、自我改造能力的人工智能，并重点关注生成式人工智能可能被用于编写恶意软件、制造生物武器或化学武器等安全风险。

5 语料安全要求

5.1 语料来源安全要求

对服务提供者的要求如下。

a）语料来源管理方面：

1）面向特定语料来源进行采集前，应对该来源语料进行安全评估，语料内容中含违法不良信息超过5%的，不应采集该来源语料；

2）面向特定语料来源进行采集后，应对所采集的该来源语料进行核验，含违法不良信息情况超过5%的，不应使用该来源语料进行训练。

b）不同来源语料搭配方面：应提高语料来源的多样性，对每一种语言的语料，如中文、英文等，以及每一种类型的语料，如文本、图片、音频、视频等，均应有多个语料来源；如需使用境外语料，应合理搭配境内外来源语料。

c）语料来源可追溯方面：

1）使用开源语料时，应具有该语料来源的开源许可协议或相关授权文件；

注1：对于汇聚了网络地址、数据链接等能够指向或生成其他数据的情况，如果需要使用这些被指向或生成的内容作为语料，应将其视同于自采语料。

2）使用自采语料时，应具有采集记录，不应采集他人已明确不可采集的语料；

注2：自采语料包括自行生产的语料以及从互联网采集的语料。

注3：明确不可采集的语料，例如已通过robots协议或其他限制采集的技术手段明确表明不可采集的网页数据，或个人已拒绝授权采集的个人信息等。

3）使用商业语料时：

—— 应有具备法律效力的交易合同、合作协议等；

—— 交易方或合作方不能提供语料来源、质量、安全等方面的承诺以及相关证明材料时，不应使用该语料；

—— 应对交易方或合作方所提供语料、承诺、材料进行审核。

4）将使用者输入信息当作语料时，应具有使用者授权记录。

d）按照我国网络安全相关法律法规及政策文件要求阻断的信息，不应作为语料。

5.2 语料内容安全要求

对服务提供者的要求如下。

a）语料内容过滤方面：应采取关键词、分类模型、人工抽检等方式，充分过滤全部语料中的违法不良信息。

b）知识产权方面：

1）应设置语料以及生成内容的知识产权负责人，并建立知识产权管理策略；

2）语料用于训练前，应对语料中的主要知识产权侵权风险进行识别，发现存在知识